

**Instituto de
Computação**

UNIVERSIDADE ESTADUAL DE CAMPINAS



Câncer de Pele e seus Tipos: uma Análise do Perfil de Expressão Gênica em Redes

MO413A - Ciência e Visualização de Dados em Saúde


Alan Freitas Ribeiro (193400)
Augusto José Peterlevitz (209783)
Felipe Kennedy Carvalho Torquato (174157)
Luis Henrique Angélico (248891)
Naruan Francisco Ferraz e Ferraz (323009)
Paulo Costa (063607)





Resumo

Este projeto visa comparar redes de interação gênica derivadas de amostras de **câncer de pele melanoma, não-melanoma e tecido saudável**. Serão analisadas as diferenças na topologia da rede, nos genes centrais e nos módulos biológicos, com objetivo de observar padrões específicos da doença e mecanismos compartilhados, fornecendo informações sobre a biologia tumoral e potenciais biomarcadores.



Câncer de pele

Classificação


- Local
- Tipo celular de origem

Tipos

- Car. Basocelular
- Car. Espinocelular
- Melanoma


Estimated number of new cases from 2022 to 2045, Both sexes, age [0-85+]
Melanoma of skin + Non-melanoma skin cancer
World

2022



1.57M

2045



2.96M



Perguntas a serem respondidas

1. Como as redes gênicas diferem entre câncer de pele melanoma, não-melanoma e tecido saudável?
2. Existem genes “exclusivos” em cada tipo de câncer? Quais são?
3. Existem vias moleculares compartilhadas entre melanoma e não-melanoma?
4. Quais interações são adquiridas ou perdidas em cada tipo de câncer?
5. Podemos identificar módulos (clusters) específicos para cada tipo de câncer?



3. Metodologia

1. Obtenção de datasets por meio do Gene Expression Omnibus (GEO)
 - Saudável
 - Melanoma
 - Não-melanoma
2. Obtenção de expressão diferencial:
 - Saudável vs Melanoma
 - Saudável vs Não-melanoma
 - Melanoma vs Não-melanoma
3. Consulta do database STRING
 - Interações entre proteínas
 - scores de confiança



3. Metodologia

4. Análise no Cytoscape

- Eigenvector centrality (CytoNCA)
- Degree e clustering coefficient (NetworkAnalyzer)
- Clusterização (clusterMaker2/MCODE)

5. Comparação entre redes

- Identificação de genes ganhos/perdidos (saudável vs não saudável)
- Identificação de genes centrais e arestas exclusivas
- Métricas (degree, betweenness centrality e closeness centrality)
- Identificação de semelhanças entre melanoma e saudável



Base de dados: Gene Expression Omnibus (GEO)

Base de dados	Dataset	Grupos
Gene Expression Omnibus (GEO)	GSE7553	Carcinoma baso celular, Melanoma in situ (estágio 0), Melanoma primário, Melanoma metastático, Carcinoma espinocelular, Pele Normal (controle)
Gene Expression Omnibus (GEO)	GSE45216	Carcinoma espinocelular, Queratose actínica
Open Targets Platform	Melanoma	-
Open Targets Platform	Carcinoma	-
The Cancer Genome Atlas Program (TCGA)	TCGA-SKCM	

Análises adicionais - Deep Learning



- Graph Attention Networks - GAT (Baseline)
 - Dataset: [TCGA-SKCM](#) (Xena Browser)
 - Modelo: GATv2Conv
 - Distribuição de classes:
 - 472 pacientes
 - 103 Primários, 368 Metástase, 1 normal
 - Filtramos os 500 Top K genes pela variância
 - Usamos um limiar de confiança do STRING (interações) de 50%
 - Treinamos por 5000 épocas

Análises adicionais - Deep Learning

- Resultados
 - Validamos o funcionamento do treinamento
 - Validamos o funcionamento da ferramenta de visualização
- Próximos passos
 - Integrar outros datasets
 - Melhorar a ferramenta de visualização de dados:
 - Adicionar opções para comparar paciente x paciente
 - Adicionar opções para comparações gerais
 - Melhorar exploração e filtragem de dados




Ferramentas


- Gene Expression Omnibus (GEO)
- Excel
- STRING
- Cytoscape
 - CytoNCA
 - NetworkAnalyzer
 - MCODE
 - clusterMaker2
- Python
 - PyTorch
 - Pandas
 - Scikit-learn



Modelo lógico da base de grafos que será construída



Workflow GSE7553 - Carcinoma vs Normal skin



Também em Python!

Decidimos replicar a análise feita em Orange em um notebook Python.

Acreditamos que em Python será mais fácil de generalizar as próximas análises.

GSE4570GSE2503GSE53462GSE8401GSE7553GSE45216

AccessionGSE7553

TitleGene Expression Patterns Involved in the Malignant Transformation and Progression of Metastatic Melanoma

PlatformGPL570

Samples87

SubmittedApr 19 2007

Metastatic melanoma is a deadly disease while non-metastatic melanoma and other cutaneous tumor types are usually cured with surgical removal of the primary tumors. This study evaluated gene expression to determine if gene expression differences existed which would allow one to identify the metastatic tumors based on the expression of specific genes.

Amostras por categoria

Categoria	N
string	Int64
Metastatic Melanoma	40
Basal Cell Carcinoma	15
Primary Melanoma	14
Squamous Cell Carcinoma	11
Microv	c

datasets_summary

Entrez ID
Int64

Gene Symbol
object
unique: 359

LogFC
float64

p-value
float64

oncogeneScore
float64 (nulls: 126)

3.664	IRF6	-3,9571028072042806	0,000000016390977499084045	0,0757794746931172
646	BNC1	-3,990035834164792	0,00000016584090168084854	0,0328542118264795
23.242	COBL	-2,497541079760399	0,000000161253629501683	0,0014783194187388
245.973	ATP6V1C2	-2,760597165700961	0,000013928169528874645	NaN
145.264	SERPINA12	-4,506124363676508	0,00000022909715160726997	0,0066524373843246
118.663	BTBD16	-2,606902472625909	0,0000663773303764481	NaN
29.841	GRHL1	-2,544255387007325	0,000029635204568224984	0,068536530829863
135.250	RAET1E	-2,5793982816542527	0,00000007380645235175733	0,0014783194187388
150.696	PROM2	-4,405809871837383	0,0000000019026386727776076	0,0815727290056273
89.777	SERPINB12	-2,5335293012816797	0,00017189923336370265	NaN

360 rows, 5 columns 10 / page

metastatic_final

```
1 expected = pd.read_csv(Path("workspace/Metastatic Melanoma/Nodes_cytoscape.csv"))
```

Comparação com baseline do Orange

Métrica	Valor
Genes no notebook	360
Genes esperados (Orange)	359
Em comum	358
Só no notebook	1
Só no Orange	0
Similaridade de Jaccard	99.72%

Status: pipeline bate ~99.7 % com o baseline Orange. Os genes só no nosso output (tipicamente 1) correspondem a um **bug conhecido do orange3-biosci.geo_soft_extractor** — ele descarta Entrez IDs com ≤ 2 dígitos (filtro `len(candidate) > 2` nas linhas 637 e 655), marcando como "?" e perdendo-os no Unique. Afeta ~139 probes de genes "antigos" (Entrez baixo): A2M (2), ACACB (32), ACADL (33), ACAT1 (38), ACP1 (52), etc.


Não replicamos o bug — nosso output inclui esses genes legitimamente.

metastatic_validate


```
1 # Salva a saída do notebook para conferência lado a lado com o Nodes_cytoscape.csv
2 out_dir = Path("output/Metastatic Melanoma")
3 out_dir.mkdir(parents=True, exist_ok=True)
4 metastatic_nodes.to_csv(out_dir / "Nodes_cytoscape.csv", index=False)
```

metastatic_save

Resultados - GSE7553




Melanoma vs Pele Normal






Carcinoma vs Pele Normal

Workflow GSE45216 (Carcinoma vs Queratose actínica)



Resultados GSE45216 (Carcinoma vs Queratose actínica)





Obrigado!