

**Instituto de
Computação**

UNIVERSIDADE ESTADUAL DE CAMPINAS



Câncer de Pele e seus Tipos: uma Análise do Perfil de Expressão Gênica em Redes

MO413A - Ciência e Visualização de Dados em Saúde

Alan Freitas Ribeiro (193400)
Augusto José Peterlevitz (209783)
Felipe Kennedy Carvalho Torquato (174157)
Luis Henrique Angélico (248891)
Naruan Francisco Ferraz e Ferraz (323009)
Paulo Costa (063607)





Resumo

Este projeto visa comparar redes de interação gênica derivadas de amostras de **câncer de pele melanoma, não-melanoma e tecido saudável**. Serão analisadas as diferenças na topologia da rede, nos genes centrais e nos módulos biológicos, com objetivo de observar padrões específicos da doença e mecanismos compartilhados, fornecendo informações sobre a biologia tumoral e potenciais biomarcadores.

LOCALIZAÇÃO PRIMÁRIA NEOPLASIA MALIGNA	ESTIMATIVA DOS CASOS NOVOS								
	Homens			Mulheres			Total		
	Casos	Taxa bruta	Taxa ajustada	Casos	Taxa bruta	Taxa ajustada	Casos	Taxa bruta	Taxa ajustada
Mama feminina	-	-	-	78.610	71,57	42,50	78.610	71,57	42,50
Próstata	77.920	74,62	45,31	-	-	-	77.920	74,62	45,31
Côlon e reto	26.270	25,16	12,34	27.540	25,07	11,10	53.810	25,11	11,39
Traqueia, brônquio e pulmão	18.730	17,95	11,95	16.650	15,14	8,90	35.380	16,51	10,53
Estômago	13.830	13,25	10,23	8.700	7,92	5,01	22.530	10,52	7,39
Colo do útero	-	-	-	19.310	17,59	14,76	19.310	17,59	14,76
Glândula tireoide	3.140	2,99	2,30	13.310	12,15	7,49	16.450	7,68	5,47
Cavidade oral	12.260	11,68	8,47	4.930	4,46	2,67	17.190	7,98	5,23
Linfoma não Hodgkin	6.580	6,30	4,35	5.980	5,45	3,18	12.560	5,87	3,95
Leucemias	6.540	6,27	4,81	5.680	5,17	3,49	12.220	5,71	4,20
Sistema nervoso central	6.500	6,25	4,85	5.560	5,07	3,81	12.060	5,64	3,95
Bexiga	9.040	8,65	4,19	4.070	3,71	1,69	13.110	6,12	2,76
Esôfago	8.750	8,37	5,53	2.640	2,40	1,23	11.390	5,31	3,41
Pâncreas	6.330	6,08	3,95	6.910	6,28	3,43	13.240	6,18	3,76
Fígado	7.240	7,02	4,80	5.010	4,50	2,11	12.250	5,70	3,07
Pele melanoma	4.930	4,71	2,38	4.430	4,02	1,73	9.360	4,36	1,92
Corpo do útero	-	-	-	9.630	8,79	5,22	9.630	8,79	5,22
Laringe	7.310	7,00	4,70	1.200	1,07	0,63	8.510	3,96	2,45
Ovário	-	-	-	8.020	7,33	5,22	8.020	7,33	5,22
Linfoma de Hodgkin	1.740	1,66	1,31	1.330	1,18	0,77	3.070	1,41	1,04
Outras localizações	38.570	36,94	25,33	32.460	29,57	18,64	71.030	33,16	21,82
Todas as neoplasias, exceto pele não melanoma	255.780	244,98	164,04	261.990	238,60	149,88	517.770	241,71	158,12
Pele não melanoma	136.180	130,42	-	127.100	115,75	-	263.280	122,90	-
Todas as neoplasias	391.960	375,41	-	389.090	354,35	-	781.050	398,32	-


Estimativa de novos casos para 2026

Melanoma: 9.360

Não-melanoma: 263.280


Estimated number of new cases from 2022 to 2045, Both sexes, age [0-85+]
Melanoma of skin + Non-melanoma skin cancer
World

2022




1.57M

2045



2.96M



Classificação

- Local
- Tipo celular de origem

Tipos

- Car. Basocelular
- Car. Espinocelular
- Melanoma



Perguntas a serem respondidas

1. Como as redes gênicas diferem entre câncer de pele melanoma e não-melanoma?
2. Existem genes “exclusivos” em cada tipo de câncer? Quais são?
3. Existem genes compartilhados entre melanoma e não-melanoma?
4. Quais interações são adquiridas ou perdidas ao longo da progressão do melanoma?
5. Podemos identificar módulos (clusters) específicos para cada tipo de câncer?



Metodologia


1. Obtenção de datasets
 - GEO
 - Open Targets
2. Obtenção de expressão diferencial:
 - Saudável vs Melanoma
 - Saudável vs Não-melanoma
 - Melanoma vs Não-melanoma
3. Consulta do database STRING
 - Interações entre proteínas
 - scores de confiança
4. Análise no Cytoscape
5. Treinamento de modelos GAT (Graph Attention Network)



Base de dados PPI



Base de dados	Dataset	Descrição
GEO	GSE7553	87 amostras (Affymetrix GPL570): BCC, Melanoma in situ, Primário, Metastático, SCC e Pele Normal (controle)
Open Targets	Melanoma (EFO_0000756)	globalScore por gene e fase clínica de evidência terapêutica — anotação dos nós com relevância clínica
Open Targets	BCC (EFO_0004193)	Anotação análoga para Carcinoma Basocelular
Open Targets	SCC (EFO_1001927)	Anotação análoga para Carcinoma Espinocelular

Resultados




$-1,5 < \text{LogFC} < 1,5$

$p\text{-value} < 0,05$




Resultados

Não-melanoma




Resultados


Melanoma



in situ



Primário



Metastático

Resultados



Seleção da maior sub-rede

Clusterização (Community Cluster)

Style: oncogenescore -> LogFC

Existem genes “exclusivos” em cada tipo de câncer?




Melanoma in situ	583
Melanoma primário	75
Melanoma metastático	43
Carcinoma espinocelular	88

Existem genes compartilhados entre os tipos de câncer?



CDK1 CDC45 CHEK1 NCAPH ZWINT	Controle do ciclo celular
RRM2 CHEK1 CDC45	Replicação e integridade genômica
IFI27 HSPB6 ATG12	Estresse e sobrevivência
CCN1	Remodelamento tumoral
MELK PBK	Proliferação


Quais as interações são adquiridas ou perdidas ao longo da progressão do melanoma?



ERBB2
HRAS
MAPK3
ETS1
HDAC4
PHGDH

AKT3
ALDH2
AQP1
ABLIM1
ABI2

Podemos identificar módulos (clusters) específicos para cada tipo de câncer?




Graph Neural Network - O que é?

O valor de um gene depende com quem ele conversa.

GNN


- Olhar conectado
- O ambiente tem impacto na entidade que está ali inserida



Fundamentação Teórica: Graph Neural Network

Neural Network

$$H^{(l+1)} = \sigma(H^{(l)}W^{(l)})$$



Graph Neural Network

$$H^{(l+1)} = \sigma\left(\tilde{D}^{-\frac{1}{2}}\tilde{A}\tilde{D}^{-\frac{1}{2}}H^{(l)}W^{(l)}\right)$$

- $H^{(l)}$: embeddings da camada l
- $W^{(l)}$: pesos a serem aprendidos no treinamento
- $\tilde{A}$: matriz adjacente
- $\tilde{D}$: matriz diagonal (normalização de dados)
- σ : função de ativação

Fundamentação Teórica: GAT

1. Score de importância por meio de mecanismo de atenção α



$$e_{ij} = a(W\vec{h}_i, W\vec{h}_j)$$

2. Normalização com Softmax

$$\alpha_{ij} = \text{Softmax}_j(e_{ij}) = \frac{\exp(\text{LeakyReLU}(e_{ij}))}{\sum_{k \in \mathcal{N}_i} \exp(\text{LeakyReLU}(e_{ik}))}$$

3. Weighted Aggregation


$$\vec{h}_i^{(l+1)} = \sigma \left(\sum_{j \in \mathcal{N}_i} \alpha_{ij} W \vec{h}_j^{(l)} \right)$$



Graph Attention Network

O mecanismo de atenção é um filtro de relevância.

- Nem todas as relações são iguais
- O Filtro de Relevância (Atenção)
- Interpretabilidade






Base de dados GAT

Base de dados	Dataset	Grupos
TCGA-SKCM (TOIL recompute)	<u>UCSC Xena</u> <u>TOIL</u>	Reprocessamento harmonizado de TCGA + GTEx (Kallisto + RSEM) para eliminar batch effect entre coortes. Tumor Primário (Class 0) e Metástase (Class 1). Valores em $\log_2(\text{TPM}+0.001)$.
GSE112509 (GEO)	<u>GSE112509</u>	23 nevos benignos + melanomas (DESeq2 normalized counts, Kunz 2018). Class 2 do GAT — usamos só os 23 nevos.
STRING v12	<u>STRING</u>	Interações proteína-proteína com combined score. Filtro: ≥ 200 , interações físicas. Define o esqueleto compartilhado dos grafos por amostra.
GENCODE v23	<u>GENCODE</u>	Tabela de equivalência Ensembl ID $\leftrightarrow$ símbolo HGNC $\leftrightarrow$ tipo de gene. Usada para mapear identificadores do TOIL e filtrar para genes protein-coding.

Base de dados: Transformações e tratamentos



1. **TOIL TPM** — baixa dados da UCSC Xena para todas as amostras TCGA + GTEx + TARGET.
2. **Phenotype** — baixa o arquivo de rótulos da Xena com tipo de tecido, *sample type* e coorte de cada amostra.
3. **GSE112509** — baixa as contagens DESeq2 normalizadas do GEO para o estudo de nevos benignos vs melanomas.
4. **GENCODE probemap** — baixa a tabela de equivalência Ensembl ID ↔ símbolo HGNC ↔ tipo de gene.
5. **STRING API** — endpoint do STRING que devolve interações físicas com *combined score*.
6. **Filtro TCGA-SKCM** — seleciona, no TOIL, apenas amostras do coorte SKCM com *sample type* "Primary Tumor" (Class 0) ou "Metastatic" (Class 1).
7. **Ensembl → HGNC** — substitui IDs Ensembl pelos símbolos HGNC do probemap, descartando linhas sem mapeamento.
8. **Seleciona nevos** — filtra o GSE112509 para reter apenas as 23 amostras de pinta (Class 2), descartando os melanomas do GEO.
9. **log2(counts+1)** — aplica $\log_2(x+1)$ às contagens DESeq2 do GSE para casar a *escala* do TOIL (não o valor absoluto).
10. **Concatena coortes** — junta as matrizes TCGA-SKCM e GSE112509 por gene em comum, formando a matriz combinada (~492 amostras).
11. **Protein-coding** — mantém apenas genes anotados como *protein-coding* no GENCODE, descartando pseudogenes/lncRNAs.
12. **Split 70/15/15** — divisão de dados em treinamento, teste e validação por classe com persistida em para evitar *leakage* nas etapas seguintes.
13. **Top-variable genes** — calcula a variância **somente nas amostras de treino do TCGA** e seleciona os `NUM_NODES = 1000` genes mais variáveis.
14. **STRING REST** — consulta o STRING para os 1000 símbolos com `required_score ≥ 200` recuperando todas as arestas físicas entre eles.
15. **edge_index único** — converte a lista de arestas em um `edge_index` **compartilhado** por todas as amostras (a topologia não muda).
16. **Per-sample x,y** — para cada amostra constrói $x \in \mathbb{R}^{\{1000 \times 1\}}$ (vetor de expressão) e $y \in \{0,1,2\}$ (rótulo de classe).
17. **Data objects** — empacota cada $(x, \text{edge_index}, y)$ em um `torch_geometric.data.Data`
18. **Saida** — serializa a lista de 492 grafos em `skcm_nevi_1000_200.pt` junto a `splits.npz` para uso reprodutível em treino/validação/teste.



Treinamento GAT

Arquitetura (`GATv2Classifier`).

Parâmetro	Valor
Camadas GATv2	3
<code>hidden_channels</code>	128
Cabeças por camada	4, 4, 1
<code>dropout</code>	0.4
Normalização	<code>LayerNorm</code> após cada camada
Pooling	<code>global_mean_pool</code>
Cabeça de classificação	<code>Linear(128 → 3)</code>
Atributo de nó (<code>in_channels</code>)	1 (expressão log)


Hiperparâmetros de treino (`src/train.py`).

Parâmetro	Valor
Otimizador	<code>Adam</code>
<code>learning_rate</code>	1e-3
<code>weight_decay</code>	5e-4
Scheduler	<code>ReduceLR0nPlateau</code> (factor 0.5, patience 10, min_lr 1e-6)
Loss	<code>CrossEntropyLoss</code>
Balanceamento	<code>WeightedRandomSampler</code> por <i>batch</i> (train only)
<code>batch_size</code>	32
<code>num_epochs</code> (máx)	500
<code>EARLY_STOP_PATIENCE</code>	50 (sobre val loss)
<code>SEED</code> (single-run)	42
Split	70/15/15 estratificado, salvo em <code>splits.npz</code>
Seleção de modelo	menor val loss observada
Device	auto: CUDA → MPS → CPU (env <code>GAT_DEVICE</code>)

Resultados classificador

O GATv2 atinge acurácia média de **$78,4 \pm 5,7 \%$** sobre 5 seeds.

Metástase é a classe mais estável ($F1 = 0,87 \pm 0,04$), Nevo Benigno ($0,57 \pm 0,12$) e Tumor Primário ($0,40 \pm 0,22$) sofrem com o desbalanço (367/102/23).



Explorando a atenção

Usando o GAT conseguimos visualizar em quais genes a rede neural estava prestando atenção enquanto aprendia a identificar câncer primário, metástase e pinta benigna.

Um ponto que se destacou foi a atenção a família de genes KRT. Encontramos na literatura que estes genes são apontados como potenciais indicadores de melanoma¹

Sample Exploration Dashboard

Filter and select samples to visually compare their Graph Attention Network mappings.

Filters

SEARCH PATIENT ID
search id...

TRUE CLASS
all classes

PREDICTED CLASS
all classes

SPLIT
train only

STATUS
correct only

MIN CONFIDENCE (0%)
0

Samples 277 matched
Select All Clear

☒ 1- TCGA-EE-A29D-06 Metastasis

☒ 3- TCGA-EE-A17X-06 Metastasis

☒ 4- TCGA-FR-A6YD-06 Metastasis

☒ 7- TCGA-D3-A3ML-06 Metastasis


☒ 8- TCGA-EE-A2MP-06 Metastasis

☒ 9- TCGA-DA-A114-06 Metastasis

☒ 10- TCGA-ER-A19S-06 Metastasis

☒ 11- TCGA-EE-A3AB-06 Metastasis

Attention Network Mappings (Mean attention of 492 sample(s))




Selected Samples Information


idx	patient id	true class	predicted	split	confidence	correct?	Use in comparison Alt Clear
-----	------------	------------	-----------	-------	------------	----------	--

¹HAN, Wei et al. Transcript levels of keratin 1/5/6/14/15/16/17 as potential prognostic indicators in melanoma patients.


Explorando a atenção



Primário vs. Metástase



Primário vs. Benigno



Benigno vs. Metástase



Análises adicionais GAT

- Embeddings
- Pseudotempo
- Biomarcadores

Embeddings — t-SNE e vizinhos próximos

O modelo processa o grafo PPI de cada amostra por três camadas GAT.

Cada um dos 1000 genes acaba com um vetor de 64 números que mistura sua própria expressão com informação ponderada por atenção de seus vizinhos PPI (e dos vizinhos deles, e assim por diante — até três hops).

O modelo então faz a média desses 1000 vetores em um único resumo 64-dimensional da amostra inteira. Esse vetor médio é o embedding.

Projeção: t-SNE Colorir por: classe verdadeira

Tumor Primário Metástase Nevo Benigno



TCGA-EB-A5VU-01

verdadeira: Tumor Primário · predita: Tumor Primário · confiança: 54,8% · **correta**


10 vizinhos mais próximos

#	amostra	classe	coseno
1	TCGA-EB-A57M-01	Tumor Primário	0,988
2	TCGA-D3-A1Q6-06	Metástase	0,985
3	TCGA-BF-A1PX-01	Tumor Primário	0,982
4	TCGA-XV-A9W2-01	Tumor Primário	0,980
5	TCGA-BF-A3DJ-01	Tumor Primário	0,978
6	TCGA-EB-A3XC-01	Tumor Primário	0,978
7	TCGA-GN-A4U9-06	Metástase	0,976
8	TCGA-D3-A1Q5-06	Metástase	0,974
9	TCGA-WE-A8ZM-06	Metástase	0,974
10	TCGA-EE-A20H-06	Metástase	0,972

Embeddings — Biomarcadores

Heatmap de atenção entre classes

Cada coluna é uma aresta PPI que o modelo trata com atenção diferente entre as três classes. Cor = atenção média sobre 5 seeds. As arestas são ordenadas por **amplitude entre classes / variabilidade entre seeds** — valores altos indicam que o modelo trata a aresta como informativa de forma consistente e a diferencia entre tipos de amostra.



Pseudotempo


Ordenamos toda amostra ao longo de um eixo de "grau de tumor" e observamos em quais genes o modelo se apoia em cada passo. Genes cuja importância cresce conforme as amostras ficam mais parecidas com tumor são candidatos a sinais de progressão de melanoma — como vistos pelo modelo.

Calculamos duas âncoras no espaço de embeddings: o embedding médio das amostras de pele Normal (a "âncora normal") e o embedding médio das amostras de Metástase (a "âncora de metástase"). Em seguida, desenhamos uma reta imaginária entre as duas e projetamos toda amostra sobre essa reta. Cada amostra recebe um número entre 0 e 1:

- 0 = embedding na âncora de pele normal
- 1 = embedding na âncora de metástase
- valores intermediários = "em algum ponto do caminho"

Dividimos esse eixo 0→1 em 10 bins de largura igual (decis) e, para cada bin, calculamos a média dos escores de atenção do modelo entre todas as amostras que caíram nele. O resultado é um retrato de quais genes o modelo foca em cada passo ao longo do eixo Normal → Metástase.

Como ler a figura: uma linha clara à esquerda e escura à direita significa "o modelo prestou atenção neste gene principalmente em amostras parecidas com normais, e deixou de se importar quando elas ficaram mais parecidas com tumor". O padrão inverso aponta para o outro lado.



Ferramentas



STRING

- Python: PyTorch, PyTorch Geometric (GATv2Conv), NumPy, Pandas, SciPy, scikit-learn, Matplotlib, Plotly, NetworkX.
- GEOquery / UCSC Xena Toolkit para baixar e harmonizar TCGA-SKCM e GSE112509.
- STRING para a rede PPI.
- Open Targets Platform para anotação de evidência terapêutica.
- Cytoscape — referência visual e validação topológica.
- Streamlit (`pipelines/python/scripts/explore_streamlit.py`
`pipelines/python/scripts/predict_streamlit.py`
`pipelines/python/notebooks/explain_gat_interactive.py`) para exploração interativa.
- Plotly + NetworkX para os gráficos interativos de subgrafos PPI.



PyTorch



python™



Cytoscape

Discussão - O que o modelo aprendeu



- Atenção destaca KRT 1, 12, 14, com sinal monotônico forte ao longo do pseudotempo
 - Convergência com literatura: KRT como prognóstico em melanoma ([Han et al. 2021](#))
- Atenção também destaca sinal imune — imunoglobulinas (IGHV3-15, IGKV2D-40, IGLV10-54) e quimiocinas (PF4/CXCL4, PPBP/CXCL7, CCL11) aparecem nos top-20, com PF4 e CCL11 dominando o contraste Metástase – Primário
 - Convergência com literatura: assinatura imune como módulo de resposta a imunoterapia em melanoma ([Murgas 2024](#) — L2-B)
- Pseudotempo preserva ordem Normal → Primário → Metástase em 5 *seeds* independentes — eixo biológico reprodutível
- GAT bate baseline topológico

Discussão - Composição Tecidual x Biologia Melanocítica

- Nevo no lugar de pele normal — nevo é uma pinta benigna, com a mesma matriz de pele do Primário; pele normal tem poucos melanócitos e a composição tecidual seria distante demais
- Melanócitos não expressam KRT nem geram resposta imune — seus marcadores são MITF, TYR, PMEL, S100; o sinal de KRT e o sinal imune vêm do tecido de fundo da biópsia *bulk*, não do tumor
 - Nevo / Primário → biópsia de pele com epiderme → alto KRT, baixo imune
 - Metástase → ~70% em linfonodo → baixo KRT, alto imune (linfócitos de fundo)
- Modelo aprende sinal estatístico real, mas que serve de proxy do sítio anatômico — não é biomarcador do melanócito em si
- Necessidade de deconvolução celular e single-cell (ver Trabalhos Futuros — Generalização)

Discussão - Limitações e virada de escopo



- Datasets pequenos — 492 amostras no total para treinar, validar e testar; nevos são apenas 23
- Classes desbalanceadas (367 Metástase / 102 Primário / 23 Nevo) — F1 alto só em Metástase (0,85); Primário (0,4) e Nevo (~0,5) sofrem mesmo com *class weights*
- Drivers mutacionais ausentes — BRAF, NRAS, TP53 ficam invisíveis: a importância deles vem de mutação, não de variação de expressão
- Primário ↔ Metástase se sobrepõem transcricionalmente (metástase é primário escapado) — teto biológico de acurácia
- Atenção é interpretabilidade *post hoc* — correlação, não causalidade; falta validação por perturbação *in silico*
- Pivô de escopo P1/P2 → P3 — saímos de 3 tipos de câncer com centralidade clássica para progressão do melanoma com GAT

Conclusão

- Use filtro solar ☀️
- Construímos um GAT funcional sobre TCGA-SKCM + GSE112509 — pipeline reprodutível em 5 seeds, acurácia 78 ± 6 %
- O modelo aprendeu sinais biologicamente coerentes — KRT e assinatura imune, com convergência em literatura ([Han et al. 2021](#), [Murgas et al. 2024](#))
- Com ressalvas — boa parte do sinal é proxy de sítio anatômico (epiderme / linfonodo); F1 desigual entre classes; atenção não é causalidade
- Pivô P1/P2 → P3 modificou a pergunta — Ao invés de comparar 3 tipos de câncer com centralidade clássica, analisamos a progressão dentro do melanoma com GAT

Trabalhos Futuros - Enriquecimento do Grafo

Atributos do Nó

- Embeddings de proteína — [ESM-2](#)
- Embeddings estruturais — [ESM-IF](#) / [Foldseek](#) / [SaProt](#) sobre estruturas do [AlphaFold DB](#)
- Mutações somáticas (e.g., BRAF, NRAS, TP53) — [TCGA MC3](#) — flag categórica ou embedding sobre sequência mutada

Atributos de Aresta

- [STRING](#) completo (7 features por aresta, ao invés de apenas topologia)
- Outras redes mais detalhadas — [KEGG](#), [Reactome](#), [SIGNOR](#), [OmniPath](#)

Nós Heterogêneos

- miRNAs — TCGA-SKCM miRSeq ([Firehose](#)) + [miRTarBase](#)
- Functional units — KEGG KGML ([hsa04010](#), [hsa05218](#)) + [Reactome](#)
- Drogas — [DGIdb](#) + [Open Targets](#) + [DrugBank](#)



Consideravelmente mais complexo

Trabalhos Futuros - Escala e Pré-treinamento



Pré-treino auto-supervisionado

- [ARCHS4](#) (~1.5M)
- [Recount3](#) (~750k)

Amostras de RNA-seq
harmonizadas:

Pré-treino supervisionado

- [TCGA pan-cancer](#) (~10k amostras, 33 tipos)

Mais dados de pele

- Expandir amostras de nevo: combinar [GSE3189](#), [GSE15605](#), [GSE46517](#) ao [GSE112509](#)
- Validação externa: [GSE65904](#) ([Cirenajwis 2015](#)) — 214 melanomas suecos com sobrevida, independentes do TCGA; permite testar classificação, pseudotempo vs sobrevida e os 4 subtipos moleculares de Cirenajwis

Trabalhos Futuros - Generalização



Composição celular

Controlar viés causado pela composição de cada tecido.

- Deconvolução: Estima fração de cada tipo celular (melanócito, TIL, fibroblasto, queratinócito) por amostra e usa para normalizar a análise — [CIBERSORTx](#), [MuSiC](#), [EPIC](#)
- Single-cell ([Tirosh 2016](#), [Jerby-Arnon 2018](#)) — resolução nativa por tipo celular; pseudo-bulk para alinhar com o pipeline atual

Estender o escopo novamente

- incluir Pele Normal, Carcinoma Basocelular (BCC), Carcinoma Espinocelular (SCC) e Queratose Actínica
- Datasets já mapeados: [GSE7553](#), [GSE45216](#), [GSE53462](#)

A partir de uma origem comum (pele normal), o modelo compara dois eixos paralelos de transformação:

- Melanocítica:
pele normal → nevo → melanoma primário → metástase
- Queratinocítica:
pele normal → queratose actínica → SCC / BCC

Referências bibliográficas



Artigos

- Han, W., Hu, C., Fan, Z.-J., & Shen, G.-L. (2021). Transcript levels of keratin 1/5/6/14/15/16/17 as potential prognostic indicators in melanoma patients. *Scientific Reports*, 11, 1023. <https://doi.org/10.1038/s41598-020-80336-8>
- Murgas, K. A., Elkin, R., Riaz, N., Saucan, E., Deasy, J. O., & Tannenbaum, A. R. (2024). Multi-scale geometric network analysis identifies melanoma immunotherapy response gene modules. *Scientific Reports*, 14, 6082. <https://doi.org/10.1038/s41598-024-56459-7>
- Veličković, P., Cucurull, G., Casanova, A., Romero, A., Liò, P., & Bengio, Y. (2018). Graph attention networks. *ICLR 2018*. <https://arxiv.org/abs/1710.10903>

Bases de dados

- Vivian, J. *et al.* (2017). [Toil enables reproducible, open source, big biomedical data analyses](#). *Nature Biotechnology*, 35, 314–316 — [UCSC Xena](#) TCGA-SKCM (TOIL recompute).
- Szklarczyk, D. *et al.* (2023). [The STRING database in 2023](#). *Nucleic Acids Research*, 51(D1), D638–D646 — [STRING v12](#).
- Barrett, T. *et al.* (2013). [NCBI GEO: archive for functional genomics data sets](#). *Nucleic Acids Research*, 41(D1), D991–D995 — datasets [GSE7553](#), [GSE45216](#), [GSE112509](#).
- IARC. [Global Cancer Observatory: Cancer Tomorrow](#) (Globocan 2022 v1.1, 08.02.2024).

Webpage

Melanoma gene network analysis

- Predictions
- Attention exploration
- What is GAT
- Dataset
- Interpretability
- Embeddings
- Pseudotime
- Stability
- Biomarkers

luisangelico.github.io/MO413A-2026/

time Converter an... Board Features · A... Backlog · Agentic... bayer-int/agentic... Backlog · Agentrix Agentic AI Infohub Ocelot AI mestrado DevOps Engineer... Sprints - Boards

Skin Cancer Gene-Network Analysis

Graph attention networks over PPI for melanoma classification

Run: run_multiseed_seed1 · split: all

Predictions Exploration What is a GAT? Run overview Dataset Interpretability Embeddings Pseudotime Stability Biomarkers

Model predictions

Click any row to inspect the per-sample graph and nearest training neighbors.

Samples

492

Accuracy

81.30%

search id...

all classes

all

train only

idx	patient id	true	predicted	split	confidence	correct?
0	TCGA-FR-A3R1-01	Primary Tumor	Metastasis	train	66.5%	✗
1	TCGA-EE-A29D-06	Metastasis	Metastasis	train	68.1%	✓
3	TCGA-EE-A17X-06	Metastasis	Metastasis	train	62.2%	✓
4	TCGA-FR-A8YD-06	Metastasis	Metastasis	train	68.2%	✓
7	TCGA-D3-A3ML-06	Metastasis	Metastasis	train	60.6%	✓
8	TCGA-EE-A2MP-06	Metastasis	Metastasis	train	65.0%	✓
9	TCGA-DA-A1I4-06	Metastasis	Metastasis	train	61.7%	✓
10	TCGA-ER-A19S-06	Metastasis	Metastasis	train	70.3%	✓
11	TCGA-EE-A3AB-06	Metastasis	Metastasis	train	57.0%	✓
12	TCGA-D3-A5GR-06	Metastasis	Metastasis	train	62.0%	✓
13	TCGA-W3-AA1R-06	Metastasis	Metastasis	train	69.5%	✓
15	TCGA-EE-A20H-06	Metastasis	Metastasis	train	51.4%	✓
17	TCGA-EE-A29M-06	Metastasis	Metastasis	train	71.5%	✓
19	TCGA-D3-A8GD-06	Metastasis	Metastasis	train	65.7%	✓
20	TCGA-D3-A5GU-06	Metastasis	Metastasis	train	68.2%	✓
21	TCGA-D3-A3C8-06	Metastasis	Metastasis	train	55.5%	✓
22	TCGA-FS-A4F2-06	Metastasis	Metastasis	train	64.8%	✓
23	TCGA-EE-A29P-06	Metastasis	Metastasis	train	65.4%	✓

Obrigado!



Contact us:

Alan Freitas Ribeiro: a193400@dac.unicamp.br

Augusto José Peterlevitz: a209783@dac.unicamp.br

Felipe Kennedy Carvalho Torquato: f174157@dac.unicamp.br

Luís Henrique Angélico: l248891@dac.unicamp.br

Naruan Francisco Ferraz: n323009@dac.unicamp.br

Paulo Costa: p063607@dac.unicamp.br